

République Algérienne Démocratique et Populaire
Ministère de l'Enseignement Supérieur et de la Recherche
Scientifique
Université des Sciences et de la Technologie Houari Boumediene
(USTHB)

Faculté d'Informatique

Rapport du module : TIAD

Année universitaire 2025 – 2026

**Analyse d'une méthode de clustering
par déplacement itératif vers les maxima de
densité**

Présenté par :

ZOUAOUI Mohamed et ZEGHOUF Samir

20 novembre 2025

Résumé

Ce rapport présente une analyse détaillée d'une méthode de clustering non-paramétrique basée sur le déplacement itératif des points vers les régions de haute densité. Contrairement aux approches classiques nécessitant la spécification a priori du nombre de groupes, cette méthode permet une identification automatique des structures de regroupement présentes dans les données. Nous étudions en particulier les fondements mathématiques de l'algorithme, la sélection optimale du paramètre de fenêtrage via la règle de Scott, ainsi qu'une implémentation pratique sur des jeux de données bidimensionnels.

1 Introduction

Les algorithmes de clustering constituent un pilier fondamental de l'apprentissage non-supervisé en science des données. Parmi les diverses approches existantes, les méthodes basées sur la densité présentent l'avantage significatif de ne pas requérir la spécification préalable du nombre de clusters, contrairement aux algorithmes de partitionnement tels que K-means.

La méthode étudiée dans ce rapport repose sur un principe élégant : chaque point de données effectue un déplacement itératif vers les zones de concentration maximale, convergeant ainsi vers des maxima locaux de la fonction de densité. Ces points de convergence définissent naturellement les centres des clusters, et le nombre de groupes émerge organiquement de la structure intrinsèque des données.

2 Fondements théoriques

2.1 Principe fondamental

L'algorithme repose sur l'estimation non-paramétrique de la densité de probabilité à l'aide d'un estimateur à noyau. Pour un ensemble de points $\{x_i\}_{i=1}^n$ dans un espace $\mathbb{R}^d$, la densité estimée en un point x s'écrit :

$$\hat{f}(x) = \frac{1}{nh^d} \sum_{i=1}^n K\left(\frac{\|x_i - x\|}{h}\right) \quad (1)$$

où K est la fonction noyau, généralement une fonction décroissante de la distance, $h > 0$ est le paramètre de fenêtrage (bandwidth), et $\|\cdot\|$ désigne la norme euclidienne.

2.2 Le vecteur de déplacement

Le gradient de l'estimateur de densité indique la direction de la plus forte augmentation de densité. Le calcul du gradient conduit à l'expression du vecteur de déplacement, appelé *shift vector* :

$$m(x) = \frac{\sum_{i=1}^n K\left(\frac{\|x_i - x\|}{h}\right) \cdot x_i}{\sum_{i=1}^n K\left(\frac{\|x_i - x\|}{h}\right)} - x \quad (2)$$

Ce vecteur pointe vers la moyenne pondérée des points voisins, où les poids sont déterminés par la fonction noyau. L'algorithme itère en déplaçant chaque point dans la direction de ce vecteur jusqu'à convergence vers un maximum local de densité.

2.3 Choix de la fonction noyau

Plusieurs fonctions noyau peuvent être utilisées. Dans notre implémentation, nous avons opté pour le noyau gaussien :

$$K(d) = \exp\left(-\frac{1}{2}d^2\right) \quad (3)$$

Le noyau gaussien présente l'avantage d'être infiniment différentiable, garantissant des trajectoires de convergence lisses. Il attribue des poids décroissants de manière continue avec la distance et possède des propriétés statistiques bien établies en estimation de densité.

3 Sélection du paramètre de fenêtrage : la règle de Scott

3.1 Problématique

Le paramètre h (bandwidth) est crucial pour la performance de l'algorithme. Un choix inapproprié peut conduire à une sur-segmentation des données avec un h trop petit, détectant des clusters artificiels dus au bruit, ou à une sous-segmentation avec un h trop grand, fusionnant des clusters distincts.

3.2 La règle de Scott

La règle de Scott [1] fournit une heuristique robuste pour la sélection automatique du bandwidth, basée sur la théorie asymptotique de l'estimation de densité. Pour un ensemble de n points dans un espace de dimension d , le bandwidth optimal est estimé par :

$$h = n^{-\frac{1}{d+4}} \cdot \sigma \quad (4)$$

où σ représente l'écart-type moyen des données, calculé comme :

$$\sigma = \frac{1}{d} \sum_{j=1}^d \sigma_j \quad (5)$$

avec σ_j l'écart-type de la j -ième dimension :

$$\sigma_j = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_{ij} - \mu_j)^2} \quad (6)$$

3.3 Justification théorique

La règle de Scott découle de la minimisation de l'erreur quadratique moyenne intégrée (MISE) de l'estimateur à noyau sous l'hypothèse d'une distribution gaussienne multivariée. Bien que cette hypothèse soit restrictive, la règle s'avère remarquablement robuste en pratique pour diverses distributions.

Le terme $n^{-\frac{1}{d+4}}$ reflète le compromis biais-variance optimal. Lorsque le nombre d'observations augmente, le bandwidth diminue progressivement, permettant une estimation

plus fine de la densité. Le taux de décroissance dépend également de la dimension d , tenant compte de la malédiction de la dimensionnalité qui complique l'estimation en haute dimension.

Cette approche élimine le besoin d'ajustement manuel du paramètre tout en s'adaptant automatiquement à l'échelle naturelle des données via l'écart-type. Le fondement théorique solide de la règle de Scott, basé sur la théorie statistique de l'estimation non-paramétrique, garantit sa robustesse même lorsque les hypothèses théoriques ne sont pas strictement vérifiées. De plus, sa simplicité computationnelle permet un calcul direct ne nécessitant que les moments d'ordre deux des données.

4 Description algorithmique

4.1 Algorithme complet

L'algorithme se décompose en trois phases principales. Le mécanisme central repose sur le déplacement itératif d'une fenêtre circulaire de rayon h autour de chaque point. À chaque itération, l'algorithme examine tous les points situés à l'intérieur de cette fenêtre et calcule leur centre de masse pondéré par le noyau gaussien. Ce centre de masse représente la direction vers laquelle la densité locale augmente. La fenêtre est alors déplacée vers cette nouvelle position, et le processus se répète. Le déplacement de la fenêtre continue jusqu'à ce que le changement de position devienne négligeable, signifiant que le point a atteint un maximum local de densité. Concrètement, lorsque la variation entre deux positions successives devient inférieure à $\epsilon = 0.01$, la convergence est considérée comme atteinte et le processus s'arrête pour ce point.

Ce mécanisme peut être visualisé comme une bille roulant sur une surface de densité : à chaque instant, elle se déplace dans la direction où la concentration de points est la plus forte, jusqu'à atteindre un sommet local où elle ne peut plus monter davantage. Chaque sommet atteint correspond à un centre de cluster potentiel.

Algorithm 1 Clustering par déplacement vers les maxima de densité

Require: Ensemble de points $X = \{x_1, \dots, x_n\}$

Ensure: Attribution des clusters pour chaque point

```
1: Phase 1 : Calcul du bandwidth
2: Calculer les écarts-types  $\sigma_1, \dots, \sigma_d$ 
3: Calculer  $\sigma = \frac{1}{d} \sum_{j=1}^d \sigma_j$ 
4: Calculer  $h = n^{-\frac{1}{d+4}} \cdot \sigma$  selon Scott (1992)
5: Phase 2 : Convergence itérative
6: for  $i = 1$  to  $n$  do
7:    $y_i^{(0)} \leftarrow x_i$ 
8:    $t \leftarrow 0$ 
9:   repeat
10:    Calculer  $m(y_i^{(t)})$  selon l'équation (2)
11:     $y_i^{(t+1)} \leftarrow y_i^{(t)} + m(y_i^{(t)})$ 
12:     $t \leftarrow t + 1$ 
13:  until  $\|m(y_i^{(t)})\| < \epsilon$ 
14:   $z_i \leftarrow y_i^{(t)}$  {Point de convergence}
15: end for
16: Phase 3 : Identification des clusters
17: Regrouper les points  $z_i$  distants de moins de  $h/2$ 
18: return Attribution des clusters
```

4.2 Critère de convergence

Un point est considéré comme convergé lorsque le déplacement devient inférieur à un seuil ϵ , typiquement fixé à 0.01 dans notre implémentation. Ce critère garantit que le point a atteint un voisinage du maximum local de densité.

4.3 Regroupement final

Les points convergeant vers des maxima locaux proches (distance $< h/2$) sont regroupés dans le même cluster. Ce seuil empirique assure que des maxima légèrement distincts dus au bruit sont fusionnés, tout en préservant les clusters véritablement séparés.

5 Résultats expérimentaux

5.1 Expérience 1 : Validation sur 5 points

Pour illustrer le fonctionnement détaillé de l'algorithme, nous avons d'abord appliqué la méthode à un ensemble de 5 points bidimensionnels. Cette configuration simplifiée permet de visualiser clairement les trajectoires de convergence de chaque point individuel.

La Figure 1 présente les résultats de cette première expérience. Le graphique de gauche montre les positions initiales des 5 points (X1 à X5) avec leurs fenêtres de voisinage (rayon $h = 1.4388$ calculé selon la règle de Scott). Le graphique central illustre les trajectoires suivies par chaque point lors du processus itératif. Chaque point suit une trajectoire distincte (représentée par une couleur différente) jusqu'à converger vers un maximum local de densité, marqué par une étoile. Le graphique de droite montre le résultat final

avec l'identification de 2 clusters distincts, représentés par les croix blanches indiquant les centres de convergence.




FIGURE 1 – Visualisation détaillée de l'algorithme sur 5 points. Gauche : positions initiales avec fenêtres de voisinage. Centre : trajectoires de convergence individuelles. Droite : clusters finaux identifiés.

Cette expérience démontre clairement que les points X1, X2, et X3 convergent vers un premier maximum de densité (Cluster 1, en rouge), tandis que les points X4 et X5 convergent vers un second maximum (Cluster 2, en bleu). Les trajectoires révèlent le processus graduel d'attraction vers les zones de haute densité, avec des déplacements successifs vers la moyenne pondérée des points voisins.

5.2 Expérience 2 : Application à un jeu de données de 260 points

Pour valider la robustesse et l'efficacité de la méthode sur des données réalistes, nous avons appliqué l'algorithme à un ensemble de 260 points bidimensionnels présentant une structure de regroupement naturelle. Les coordonnées des points s'étendent sur $[-3.5, 10.7] \times [-4.7, 9.8]$.

5.2.1 Calcul du bandwidth

Application de la règle de Scott avec les paramètres suivants :

$$n = 260 \quad (7)$$

$$d = 2 \quad (8)$$

$$\sigma_x = \sqrt{\frac{1}{260} \sum_{i=1}^{260} (x_i - \bar{x})^2} \quad (9)$$

$$\sigma_y = \sqrt{\frac{1}{260} \sum_{i=1}^{260} (y_i - \bar{y})^2} \quad (10)$$

$$\sigma = \frac{\sigma_x + \sigma_y}{2} \quad (11)$$

$$h = 260^{-1/6} \cdot \sigma \quad (12)$$

Le bandwidth calculé permet d’obtenir un équilibre optimal entre la finesse de la détection et la robustesse au bruit.

5.2.2 Convergence et identification des clusters

La Figure 2 présente les résultats complets de cette expérience. Le graphique de gauche montre l’ensemble des trajectoires de convergence pour les 260 points, chaque trajectoire étant représentée par une couleur distincte. Cette visualisation révèle clairement les bassins d’attraction associés à chaque maximum de densité. On observe que les points initialement dispersés convergent de manière cohérente vers quatre régions distinctes de l’espace.

Le graphique de droite présente le résultat final du clustering. L’algorithme a identifié automatiquement 4 clusters distincts sans spécification préalable de ce nombre :

- **Cluster 1 (bleu)** : Situé dans la région supérieure du graphique, environ 50 points
- **Cluster 2 (rouge)** : Localisé dans la région inférieure droite, environ 40 points
- **Cluster 3 (rose)** : Occupant la région centrale, le cluster le plus dense avec environ 130 points
- **Cluster 4 (cyan)** : Positionné dans la région droite, environ 40 points

Les centres de clusters, marqués par des croix blanches, correspondent aux maxima locaux de densité vers lesquels les points ont convergé.




FIGURE 2 – Résultats sur 260 points. Gauche : trajectoires de convergence de tous les points. Droite : identification finale de 4 clusters avec leurs centres (croix blanches).

5.2.3 Analyse de la convergence

L’algorithme converge typiquement en 10 à 20 itérations par point pour ce jeu de données. Les trajectoires observées démontrent plusieurs propriétés importantes de la méthode. Premièrement, les points proches spatialement tendent à suivre des trajectoires similaires et convergent vers le même maximum local. Deuxièmement, la longueur des trajectoires varie selon la position initiale du point par rapport aux maxima de densité. Les points initialement éloignés des centres effectuent des déplacements plus importants. Troisièmement, les frontières entre clusters émergent naturellement des bassins d’attraction, sans nécessiter de définition explicite.

5.2.4 Interprétation des résultats

Cette expérience illustre plusieurs avantages de la méthode. Le nombre de clusters émerge naturellement de la structure des données sans paramétrage préalable. L'algorithme détecte correctement les quatre groupes distincts présents dans les données, même avec des densités et des tailles variables. Les formes des clusters ne sont pas contraintes à être convexes ou sphériques, comme c'est le cas avec K-means. La méthode s'adapte aux formes arbitraires des concentrations de points. Le processus de convergence est stable et cohérent, tous les points convergent de manière déterministe vers des maxima locaux bien définis. Enfin, la règle de Scott fournit un bandwidth approprié sans nécessiter d'ajustement manuel, démontrant sa robustesse théorique.

6 Optimisation par fusion des clusters chevauchants

L'algorithme de déplacement vers les maxima de densité peut créer des micro-clusters artificiels dans les zones de transition entre groupes naturels. Lorsque deux régions denses sont connectées par une zone moins dense, l'algorithme identifie plusieurs centres de convergence distincts, créant une sur-segmentation qui ne reflète pas la structure réelle des données.

Pour remédier à ce problème, nous proposons une étape d'optimisation post-convergence basée sur l'analyse des chevauchements entre clusters. Si les fenêtres centrées sur deux centres distincts s'intersectent, cela suggère qu'ils appartiennent à une même structure. La densité de chaque cluster, calculée via le noyau gaussien, permet ensuite de réaliser une fusion pondérée qui préserve l'information structurelle.

6.1 Formalisation mathématique

Deux clusters C_i et C_j avec centres μ_i et μ_j sont candidats à la fusion si leurs fenêtres se chevauchent :

$$\|\mu_i - \mu_j\| < 2h \quad (13)$$

Pour un cluster C contenant les indices de points $\{i_1, i_2, \dots, i_k\}$ avec centre μ_C , la densité est calculée par :

$$\rho_C = \sum_{j \in C} \exp \left(-\frac{1}{2} \left(\frac{\|x_j - \mu_C\|}{h} \right)^2 \right) \quad (14)$$

Cette métrique quantifie la concentration locale des points. Un cluster avec des points proches de son centre aura une densité élevée, tandis qu'un cluster dispersé aura une densité faible.

Lorsque deux clusters satisfont le critère d'intersection, leur fusion produit un nouveau cluster $C_{fusionné} = C_i \cup C_j$ avec un centre calculé par moyenne pondérée :

$$\mu_{fusionné} = \frac{\rho_i}{\rho_i + \rho_j} \mu_i + \frac{\rho_j}{\rho_i + \rho_j} \mu_j \quad (15)$$

Les poids $w_i = \frac{\rho_i}{\rho_i + \rho_j}$ et $w_j = \frac{\rho_j}{\rho_i + \rho_j}$ garantissent que les clusters plus denses exercent une influence proportionnellement plus importante sur la position du centre fusionné.

6.2 Justification de la pondération par densité

Plusieurs stratégies de fusion ont été considérées. La fusion par cardinalité (garder le cluster avec le plus de points) ignore la structure géométrique : dix points dispersés auraient priorité sur cinq points concentrés, ce qui contredit l’objectif de l’algorithme. La conservation du cluster dominant (éliminer le plus petit) entraîne une perte d’information car la position du cluster absorbé est ignorée. La moyenne arithmétique simple traite tous les clusters également, sans considérer leur densité.

La pondération par densité présente trois avantages principaux. Elle préserve la cohérence avec l’estimation de densité par noyau gaussien utilisée dans l’algorithme. Elle assure une robustesse au bruit car les micro-clusters transitoires, ayant une faible densité, exercent une influence limitée. Enfin, elle garantit que le centre fusionné se situe sur le segment reliant les deux centres originaux, avec une position déterminée par un critère objectif.

6.3 Algorithme de fusion

Le processus de fusion est appliqué de manière itérative jusqu’à ce qu’aucune paire de clusters ne satisfasse le critère d’intersection. Pour chaque paire de clusters dont les fenêtres se chevauchent, nous calculons leurs densités respectives, déterminons les poids de fusion, calculons le nouveau centre pondéré, et fusionnons les deux clusters. Le processus se répète jusqu’à stabilisation, ce qui survient généralement en quelques itérations.

6.4 Validation expérimentale

Pour illustrer l’efficacité de cette optimisation, nous avons conçu un jeu de données synthétique représentant une structure en forme de ”8”, composée de deux régions denses connectées par une zone de transition. Le jeu de données comprend 9 points organisés en trois régions : une région supérieure avec les points $(0, 2)$, $(0.5, 2.5)$, $(1, 2)$, $(0.5, 1.5)$, une zone de jonction avec le point $(0.5, 1.0)$, et une région inférieure avec les points $(0, 0)$, $(0.5, -0.5)$, $(1, 0)$, $(0.5, 0.5)$.

Cette configuration représente un cas typique de structure continue fragmentée artificiellement par l’algorithme de base. Les deux régions forment des concentrations locales distinctes, mais sont reliées par le point de jonction qui constitue un pont topologique.

L’application de la règle de Scott avec $n = 9$ et $d = 2$ produit un bandwidth $h \approx 0.4622$. Ce paramètre est suffisamment petit pour distinguer les deux concentrations principales, mais suffisamment grand pour que leurs fenêtres se chevauchent au niveau de la zone de transition.

6.4.1 Résultats

La Figure 3 montre la comparaison entre la segmentation initiale et le résultat après optimisation. Le graphique en bas à gauche révèle que l’algorithme identifie initialement 5 clusters distincts : deux groupes dans la région supérieure, un micro-cluster isolé au point de jonction, et deux groupes dans la région inférieure. Cette fragmentation ne reflète pas la structure naturelle des données.




FIGURE 3 – Comparaison de la segmentation avant et après optimisation sur une structure en "8". En haut à gauche : positions initiales avec fenêtres de voisinage. En haut à droite : trajectoires de convergence. En bas à gauche : 5 clusters avant optimisation avec chevauchements visibles. En bas à droite : 2 clusters après fusion optimisée.

Le processus d'optimisation procède par fusions successives. Les clusters de la région supérieure sont d'abord fusionnés entre eux, puis avec le micro-cluster de jonction. De même, les clusters de la région inférieure sont regroupés. Le résultat final produit 2 clusters qui correspondent aux deux régions de concentration principale. Le point de jonction est correctement intégré dans l'une des structures plutôt que de former un artefact isolé.

La visualisation (Figure 3, bas à droite) montre les deux fenêtres finales avec leurs centres marqués par des croix. Les cercles en pointillés de rayon h illustrent les bassins d'attraction finaux. L'optimisation a réduit le nombre de clusters de 5 à 2, éliminé le micro-cluster de jonction, et produit des clusters avec des densités comparables qui reflètent la structure topologique réelle des données.

7 Conclusion

Cette méthode de clustering par déplacement itératif vers les maxima de densité constitue une approche puissante et élégante pour l'analyse non-supervisée de données. Son principe fondamental, suivre le gradient de densité estimée, permet une identification naturelle des structures de regroupement sans nécessiter de spécification a priori du nombre de clusters.

La règle de Scott fournit une heuristique robuste pour la sélection automatique du paramètre critique de fenêtrage, équilibrant efficacement le compromis biais-variance inhérent à l'estimation non-paramétrique de densité. Cette automatisation renforce la praticité de la méthode en contexte appliqué.

Les expérimentations menées sur deux jeux de données de tailles différentes démontrent la capacité de l'algorithme à identifier correctement les structures de regroupement, de la validation détaillée sur 5 points à l'application réaliste sur 260 points. Les visualisations des trajectoires de convergence fournissent une compréhension intuitive du processus et confirment la cohérence théorique de l'approche.

L'algorithme demeure un outil précieux pour l'analyse exploratoire, particulièrement lorsque la structure des clusters est complexe ou inconnue a priori. Les extensions futures pourraient inclure des stratégies d'accélération basées sur des structures de données spatiales, ainsi que des adaptations pour gérer efficacement la haute dimensionnalité.

Références

- [1] Scott, D. W. (1992). *Multivariate Density Estimation : Theory, Practice, and Visualization*. John Wiley & Sons.